

Vila de Personas · avaliação da solução e plano final

Hackathon Itaú 2026 · Case C · Jornada de agentes · 26/09/2026, por volta das 22h30 (Brasília)

Base da avaliação: Guia dos Participantes [1], Guia de Dicas dos Mentores [2], pesquisa consolidada do time [3] e o que está no repositório (branch `claude/magical-pasteur-pcmsly`). O que depende de pessoas (teste, decisões, contas) está marcado como pendência do time.

Veredito em cinco linhas

- 1. **A solução responde ao Case C.** Ela atua num ponto só da passagem da squad (o teste) e tem entrada, trabalho da IA, revisão humana e resultado registrado, que é o que a banca precisa enxergar [1].
- 2. **Falta a evidência central: o teste com 3 a 5 pessoas.** Sem ele não existe a comparação "vila x pessoas", e a ficha e o vídeo ficam só com simulação.
- 3. **Hoje existem dois motores.** A vila em Python/Streamlit já rodou com IA de verdade (36 tentativas medidas). O laboratório em Next.js, novo, tem o fluxo completo e é bom de demonstrar, mas usa IA **simulada**. Duas versões na apresentação confundem [2, dica 10].
- 4. **A especificação multiagentes aumenta o escopo.** O próprio guia diz que "criar mais agentes não significa criar mais valor" [1], e os mentores pedem para evitar funcionalidades que não testam a hipótese [2, dica 3]. Os números vêm de código e as decisões são humanas, o que ajuda, mas é preciso justificar na fala.
- 5. **Decisões que só o time pode tomar:** qual motor aparece no vídeo, se as telas usam as cores do Itaú (a regra do próprio time proíbe) e a frase-guia final.

1. O que está pronto

Parte	Situação	Onde
Vila (Python/Streamlit), IA real	✅ simulação oficial: 4 personas x 3 telas x 3 rodadas = 36 tentativas, 0 falhas, 1.195 s. A e B: 0 de 3 para todas; C: 3 de 3	<code>vila-de-personas/resultados/demo.json</code>
Painel Streamlit com decisão humana	✅ testado de ponta a ponta no navegador	<code>vila-de-personas/app.py</code>
Comparação vila x pessoas	✅ pronta para receber as notas (com "repetida" para frases diferentes do mesmo problema)	<code>vila-de-personas/vila/comparacao.py</code>
Laboratório multiagentes (Next.js)	✅ os 4 módulos pedidos, testados no navegador; IA simulada por padrão, Groq opcional (não testada aqui)	<code>vila-lab/</code>
Pesquisa consolidada e revisada	✅ 26 evidências conferidas, incluindo as que vão contra a ideia	<code>backend/pesquisa/output/00-consolidado.md</code>
Roteiro do vídeo e da demo ao vivo	✅ com o resultado real da vila	<code>vila-de-personas/docs/roteiro-demo.md</code>
Ficha do Produto	⚠️ rascunho: 144 palavras no press release, 5 perguntas, 10 fontes; faltam os números do teste	<code>vila-de-personas/docs/ficha-do-produto.md</code>
Protocolo do teste com pessoas	✅ 1 página, mesma regra de "concluiu" da vila	<code>vila-de-personas/docs/protocolo-teste-pessoas.md</code>
Link público, vídeo, slides, teste com pessoas	❌ dependem do time	—

2. Aderência ao Case C

O que o guia pede [1]	Como a solução atende	Situação
Investigar um ponto da passagem, "em vez de tentar automatizar tudo"	O ponto é o teste: antes da rodada com usuários, a vila aponta onde cada perfil trava	✅

O que o guia pede [1]	Como a solução atende	Situação
Um fluxo com "entrada definida, saída útil e um ponto claro de revisão"	Entrada: versões da tela, tarefa e personas. Saída: onde cada perfil trava, por quê e com que frequência. Revisão: designer ou PO decide, e fica registrado	✓
"Mostrem a entrada, o trabalho realizado, a revisão humana e o resultado registrado"	Os dois motores mostram as quatro etapas; o registro de decisões só cresce	✓
"Testem um caso normal e outro incompleto ou incorreto"	Streamlit: chamada que falha vira "Incompleto". Lab: resposta do agente fora da tela é recusada e registrada (teste com 15% de respostas inválidas: 14 recusadas, 4 agentes encerrados e fora das taxas)	✓ mostrar na demo
Comparar tempo, qualidade ou retrabalho com a forma atual, "indicando o que foi medido e o que foi estimado"	Tempo da vila medido (1.195 s). Falta o lado das pessoas: acertos, pontos cegos, alarmes falsos e duração das sessões	✗ depende do teste
"Criar mais agentes não significa criar mais valor"; "um fluxo com um agente pode ser suficiente"	A vila usa um agente. O Lab usa três, mas os números vêm de código e o analista e o designer são opcionais	⚠ justificar
Não conectar a sistemas reais nem aprovar mudança de produção automaticamente	Banco fictício e dados sintéticos; o designer só propõe	✓
Quatro entregas: protótipo com link, até 10 slides, vídeo público de até 2 min, ficha de até 2 páginas	Protótipo ✓ sem link público; ficha em rascunho; slides e vídeo por fazer	⚠

3. Aderência às 10 dicas dos mentores [2]

Dica	Situação	O que fazer
1 · Problema em uma frase	⚠ a frase está na proposta, mas não foi aprovada	Sugestão: "Ajudamos o designer e o PO de uma squad a descobrir onde clientes com perfis diferentes travam numa tela nova, porque hoje isso só aparece na rodada de teste com usuários." Abram o pitch com ela, não com "criamos agentes".
2 · Conexão com o case	✓ território "apoiar a preparação de testes" do Case C	Citar o território no slide 1. As conversas com itubers não foram registradas (input/conversas.md): sem elas, a dor é hipótese.
3 · Entrega que caiba no tempo	⚠ o Lab novo aumentou o escopo	Congelar funcionalidades agora. Uma jornada: tela A x C do Pix recorrente.
4 · Pesquisar o que já existe	⚠ há estudos acadêmicos comparando IA e pessoas [3, itens 1 a 5], mas não um benchmark de produtos	Um slide "o que já existe x o que fazemos diferente": governança, comparação medida com pessoas e rótulo de simulação. Só citar produto com fonte.
5 · Valor para usuário e negócio	⚠ valor para a squad descrito; para o negócio, só hipótese	Ligar a menos retrabalho e rodadas de teste melhor aproveitadas; para o cliente, menos atrito em tarefas como o Pix recorrente. Tudo como hipótese.
6 · Métrica de sucesso	⚠ proposta pronta, sem número	Métrica principal: parte dos problemas das pessoas que a vila também apontou. Limite que não pode piorar: alarmes falsos. Apoio: tempo da tela nova até a decisão de testar.
7 · Justificar a IA	✓ bom argumento	A IA entra onde precisa ler a tela e agir como um perfil. Onde uma regra resolve, usamos regra: contraste WCAG calculado, lista de jargões, estatísticas. Custo medido: 95.598 tokens na simulação oficial.
8 · Experiência e dados	✓ dados sintéticos declarados na tela	Dizer em uma frase de onde vêm os dados (fictícios), onde ficam (navegador/JSON) e o que é simulado.
9 · Dividir e registrar decisões	⚠	Registrar por que escolheram o motor do vídeo e as cores (tabela curta no PLANO- GRAVACAO- E- PENDENCIAS.md).

Dica	Situação	O que fazer
10 · História clara	⚠️ risco de jargão técnico (MDP, π(a s))	Arquitetura só em apêndice. Na fala: "personas de IA tentam a tarefa; o designer decide o que levar ao teste com pessoas".

4. A especificação multiagentes: o que foi feito

Pedido	Situação	Observação
Next.js (App Router), React, Tailwind, Lucide, recharts	✓	Next 16.3.6, React 19.2, Tailwind 4.3, lucide-react 1.48, recharts 3.10
Tipos em TypeScript primeiro; componentes granulares	✓	src/lib/tipos.ts; um componente por tela e por seção
M1 · base sintética com as 4 partições e proporção configurável	✓	Proporção exata (2× servidores = 20 e 10 em 60); mesma semente, mesma base
M2 · app mobile-first, Home, empréstimo em 3 etapas	✓	Mais o Pix recorrente A/B/C, para ligar com a vila e com o teste com pessoas
M2 · cores #EC7000 e #1E2A4F	⚠️ feito como pedido	Conflita com a regra do time ("sem cores do Itaú"). As cores ficam num lugar só (globals.css). Decidam.
M2 · data-action-id, posição e árvore de acessibilidade em JSON	✓	Com contraste WCAG calculado de verdade e carga cognitiva por regra
M3 · /lab e botão flutuante discreto	✓	
M3 · loop via API: árvore → prompt com persona → próximo passo	✓	Resposta validada: ação fora da tela é recusada e registrada
M3 · restrição "literacia baixa + carga alta → falhar ou demorar"; saída action_id ou ABANDONAR	✓	No prompt e na política simulada
M3 · IA simulada com setTimeout na 1ª iteração	✓	Modo Groq pronto, mas não testado (a rede deste ambiente bloqueia a Groq)
M4 · /dashboard com sucesso por segmento, tempo e abandono	✓	Paleta validada para daltonismo; cada gráfico tem tabela
M4 · agente analista e agente designer	✓	Números e achados por código; a IA só redige
(acrescentado) revisão humana registrada	✓	O Case C exige; o designer não aplica nada sozinho

Riscos da especificação: - Resultado circular. No modo simulado, as taxas refletem as regras que escrevemos: a versão simplificada "ganha" porque a regra penaliza jargão. Serve para testar o sistema, nunca como evidência. - **Personas por profissão e renda.** Segmentar por "servidor × CLT" pode virar estereótipo. A pesquisa mostra que a IA tende a achatar grupos [3, itens 4 e 5]. O comportamento no Lab depende da literacia digital e da carga da tela, não da profissão; digam isso. - **Frontend novo.** O Lab foi feito para receber outra interface: basta seguir o contrato de data-action-id, data-tela e data-leitura (vila-lab/README.md).

5. Recomendação: uma história só

Critério	Vila (Streamlit)	Lab (Next.js)
IA de verdade já rodou	✓ 36 tentativas, 0 falhas	✗ só simulada até agora
Resultado medido para citar	✓ tempo e conclusões por versão	✗ números circulares
Demonstração visual	⚠️ tabelas	✓ o agente navega na tela, dashboard com gráficos
Governança completa	✓ decisão por persona	✓ achados → propostas → decisão
Pronto para o frontend novo	✗ lê imagens	✓ contrato de data-action-id

Recomendação: no vídeo e na demo, usem o **Lab** só se, antes de gravar, ele rodar com a Groq no computador de vocês (4 a 8 agentes) e com o frontend final. Se não der, usem **a vila em Streamlit**, que tem IA real e resultado medido, e mostrem o Lab no slide de próximos passos. Não mostrem os dois como produtos diferentes.

6. O que só vocês podem fazer (em ordem)

#	Quem	Tarefa	Pronto quando
1	Time	Decidir o motor do vídeo (seção 5) e as cores (Itaú x banco fictício) e registrar o porquê	decisão escrita
2	M3 + time	Aprovar a frase-guia e as 4 personas	frase no vila-de-personas/AGENTS.md
3	Raphael	Mandar o frontend final. Eu adapto ao contrato do Lab e, se as telas A/B/C mudarem, refazemos a simulação oficial	frontend no repositório
4	M1	Se for usar o Lab: <code>.env.local</code> com a chave da Groq e rodar 1 agente para validar o modo real	"IA: ligada" e 1 agente concluído
5	M4 e M3	Teste com 3 a 5 pessoas pelo protocolo	notas na planilha
6	M1	Comparação (Passo 9 do STATUS) e números nos textos	numeros-finais.md
7	M2	Publicar o link (Streamlit Cloud para a vila; Vercel para o Lab, se for o escolhido)	link abre em janela anônima
8	M2 + M4	Gravar e publicar o vídeo (roteiro pronto)	vídeo público no YouTube
9	M3 e M4	Ficha final em PDF (até 2 páginas) e slides (até 10)	PDFs no GitHub
10	Todos	Checklist do guia, envio com confirmação de recebimento e ensaio de 4 min	confirmação recebida

7. Perguntas prováveis da banca

Pergunta	Resposta curta
Por que usar IA, e não só regras?	A IA lê a tela e age como um perfil. Onde a regra basta (contraste, jargão, contas), usamos regra.
A vila substitui o teste com pessoas?	Não. Ela escolhe o que levar ao teste; comparamos com [N] pessoas e mostramos onde errou.
Como vocês sabem que a IA não inventou?	Os números vêm do código; o agente só escolhe ações que existem na tela; ação inválida é recusada e registrada.
E o viés das personas?	Personas por comportamento; a própria pesquisa mostra o risco de estereótipo [3]; por isso a comparação com pessoas.
Quanto custa?	Simulação oficial: 95.598 tokens em 36 tentativas, cerca de 20 minutos no plano gratuito.
O que falta para um piloto?	Squad real, várias telas, modelo e ambiente aprovados pelo banco, sem dado de cliente.

Fontes

- Hackathon Itaú 2026, "Guia dos Participantes", 2026 (PRIMÁRIA para as regras do evento; seção "Case C · Jornada de agentes" e "Preparem a apresentação e a demo").
- Hackathon Itaú 2026, "Dicas dos mentores para a entrega final", 2026 (PRIMÁRIA; dicas 1 a 10 e "Checagem final da equipe").
- Pesquisa consolidada do time, `backend/pesquisa/output/00-consolidado.md`, 26/09/2026 (itens 1 a 5 sobre limites de usuários simulados; fontes e limites de cada item estão lá).